

A7608 컴퓨터비전 Chapter 3.2

비지도학습

Draft

2026-03-29

발표 흐름

개요

K-means

PCA + DBSCAN

정리

비지도학습

- 레이블 없이 데이터 구조를 찾는 학습 방식
- 대표 작업: 군집화, 차원 축소, 밀도 기반 탐색
- Chapter 3.2 실습은 K-means와 PCA 기반 시각화에 초점

세미나 진행 방식

이번 발표의 흐름

- 교재에서 개념을 먼저 설명한다.
- 같은 내용을 `python_3장.ipynb`의 해당 셀에서 바로 확인한다.
- 발표 중간에 “자, 여기 실습해보아요” 흐름으로 노트북을 실행한다.

노트북 기준

- K-means: 셀 34-39
- PCA + DBSCAN: 셀 40-47

K-means 핵심 개념

- 목표는 비슷한 데이터끼리 같은 군집으로 묶는 것이다.
- K-means는 군집 개수 k 를 먼저 정하고, 각 군집의 중심을 반복적으로 갱신한다.
- 결과 해석의 핵심은 “몇 개의 군집으로 보는 것이 자연스러운가”이다.
- 실습에서는 엘보우 곡선을 사용해 k 를 고르는 감각을 만든다.

K-means Notebook 흐름

교재 설명 뒤 바로 확인할 셀


- 셀 34: K-means 섹션 시작
- 셀 35-36: 데이터 로드와 기본 확인
- 셀 37: Channel, Region 원-핫 인코딩
- 셀 38: MinMaxScaler로 정규화
- 셀 39: $k = 1$ 부터 14까지 inertia 계산 후 엘보우 곡선 그림

발표 멘트 포인트

- 범주형 변수는 숫자로 바꾸지 않으면 거리 계산이 왜곡된다.
- 스케일이 큰 특성이 중심 업데이트를 지배하지 않도록 정규화가 필요하다.
- 여기서부터는 책 설명을 멈추고 노트북으로 넘어가 바로 돌려볼 수 있다.

K-means 실습 결과 해석

- 데이터: sales data.csv
- 전처리: 범주형 원-핫 인코딩, 수치형 정규화
- 핵심 메시지: 관성(inertia) 감소 곡선이 급하게 꺾이는 구간을 찾는다.
- 발표 중에는 “왜 k 가 커질수록 inertia는 항상 감소하는가”를 먼저 짚어주면 좋다.



실습 전환 멘트: K-means

슬라이드에서 노트북으로 넘어가는 순간

“여기까지가 교재가 말하는 K-means의 개념입니다. 이제 같은 내용을 노트북 셀 34번부터 39번까지 직접 보면서, 범주형 인코딩과 정규화가 어떻게 들어가고 엘보우 곡선이 어떻게 만들어지는지 확인해보겠습니다.”

실행할 것

- `python_3장.ipynb` 셀 34-39
- 결과 그림: `slides/figures/kmeans_elbow.png`

PCA가 필요한 이유

- 고차원 데이터는 그대로는 눈으로 군집 구조를 보기 어렵다.
- PCA는 분산이 큰 방향을 기준으로 축을 다시 잡아 저차원 표현을 만든다.
- 실습에서는 여러 소비 패턴 특성을 2차원으로 줄여 시각화 가능한 공간으로 바꾼다.
- 즉, PCA는 군집 알고리즘 자체라기보다 “구조를 보이게 만드는 전처리” 역할이다.

PCA + DBSCAN Notebook 흐름

교재 설명 뒤 바로 확인할 셀

- 셀 40: PCA 섹션 시작
- 셀 41-42: 데이터 로드, CUST_ID 제거, 결측치 처리
- 셀 43: 표준화, 정규화, PCA 2차원 투영
- 셀 44-47: DBSCAN 실행과 min_samples 변화 비교


발표 멘트 포인트

- PCA를 한 뒤에야 점들을 2차원 평면에서 눈으로 읽을 수 있다.
- DBSCAN은 군집 수를 미리 정하지 않고, 밀도가 낮은 점을 노이즈로 볼 수 있다.
- 여기서부터는 파라미터를 바꾸며 “군집이 어떻게 사라지고 노이즈가 늘어나는가”를 보여주면 된다.


차원 축소와 군집 시각화

- 데이터: `credit card.csv`
- 전처리: 결측치 보완 후 표준화, 정규화
- PCA로 고차원 특징을 2차원으로 축소
- 그 위에서 DBSCAN을 적용해 군집과 노이즈를 함께 해석


DBSCAN 결과 비교



min_samples = 3



min_samples = 50



min_samples = 100

DBSCAN 해석 포인트

- `min_samples=3`에서는 작은 밀도 집단도 군집으로 인정되기 쉽다.
- `min_samples`를 키우면 더 조밀한 집단만 군집으로 남고, 많은 점이 노이즈로 밀려난다.
- 따라서 DBSCAN은 “군집 수를 몇 개로 할까”보다 “얼마나 촘촘해야 군집으로 볼까”를 묻는 알고리즘이다.
- 이 비교는 셀 45-47을 순서대로 실행하면서 보여주기 좋다.

실습 전환 멘트: PCA + DBSCAN

슬라이드에서 노트북으로 넘어가는 순간

“이제 PCA가 데이터의 구조를 보이게 만들어 준 상태에서, DBSCAN의 `min_samples` 값을 바꾸면 군집과 노이즈 해석이 어떻게 달라지는지 직접 보겠습니다. 노트북 셀 40번부터 47번까지가 바로 이 흐름입니다.”

실행할 것

- `python_3장.ipynb` 셀 40-47
- 비교 포인트: 전처리, PCA 2축 생성, DBSCAN 파라미터 변화

정리

- K-means는 군집 수를 먼저 정하고, 엘보우 곡선으로 적절한 k 를 가늠한다.
- PCA는 고차원 데이터를 2차원으로 줄여 구조를 읽기 쉽게 만든다.
- DBSCAN은 군집 수를 미리 정하지 않고, 밀도에 따라 군집과 노이즈를 함께 판단한다.
- 이번 세미나는 교재 설명 후 곧바로 노트북 셀을 실행하는 방식으로 진행한다.

노트북 체크리스트

K-means

- 셀 34-39
- 데이터 로드, 원-핫 인코딩, 정규화, 엘보우 곡선

PCA + DBSCAN

- 셀 40-47
- 결측치 처리, 표준화, 정규화, PCA, DBSCAN 비교