

이미지 분류를 위한 CNN 신경망 아키텍처

LeNet-5부터 ResNet까지, 한계점과 방향성의 이해

Overview: CNN 아키텍처의 트렌드 변화

CNN 발전 타임라인 가이드라인 (1998 ~ 2015)

1998년 LeNet-5에서 시작된 이미지 모델의 패러다임 변화

2012년 AlexNet의 등장으로 가속화된 딥러닝 혁명과 대중화

2014년 VGGNet(단순함/깊이)과 GoogLeNet(병렬화/효율성)의 아키텍처 경쟁

2015년 ResNet의 지름길 구조를 통한 레이어 깊이의 한계 정복

핵심 메시지

성능 향상을 위해 망을 '더 깊게' 쌓아가는 과정에서 마주한 한계와 이를 극복한 아이디어들

LeNet-5 (1998) – CNN의 시작과 기본 틀 정립

탄생 배경


Yann LeCun 교수가 우체국 필기체 우편번호 인식을 위해 개발

최초로 합성곱과 풀링 연산을 효과적으로 결합하여 컴퓨터 비전의 초석 마련

아키텍처 핵심 특징 및 구조

Input (32x32 흑백) ➡ Convolution ➡ Sub-sampling (Pooling) ➡ Full Connection

공간 정보를 보존하며 특징을 추출하는 현대 CNN의 표준 뼈대 구축



$$\text{Output} = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$

W (Input Size): 입력 데이터의 크기 (가로 또는 세로)


K (Kernel Size): 커널(필터)의 크기

P (Padding Size): 패딩의 크기

S (Stride Size): 스트라이드(이동 간격)의 크기

LeNet-5의 구조적 한계

- 입력데이터: 1채널 소형 흑백 이미지 입력으로 사용 ➡ 현대의 224x224x3 RGB 처리 시 문제 발생
- 활성화 함수: Sigmoid 및 Tanh 사용 ➡ 층이 깊어질수록 기울기 소실(Vanishing Gradient) 발생
- 풀링 방식: Average Pooling 사용 ➡ 특징의 강한 신호를 보존하는 데 상대적 불리



전환 브릿지: 암흑기에서 도약으로

LeNet-5 이후 10여 년간의 공백과 정체기

연산량의 부족, 대규모 데이터셋의 부재, 깊은 망 학습 시 발생하는 기울기 소실로 학계에서 외면

AlexNet이 등장하게 된 패러다임의 변화

2010년대 인터넷의 발전으로 ImageNet과 같은 빅데이터 구축 완료

CPU 연산의 한계를 뛰어넘는 GPU 컴퓨팅 파워의 보급으로 거대한 신경망 학습 조건 충족

AlexNet (2012) – 구조적 혁신과 대중화

역사적 사건: ILSVRC 2012 우승

이미지 인식 대회(ILSVRC)에서 기존 컴퓨터 비전 알고리즘을 압도적인 성격 차이로 제치고 우승
전 세계 컴퓨터 비전 연구의 패러다임을 딥러닝(Deep Learning) 중심으로 완전히 전환시킴

기본 스펙 및 하드웨어 구성

224x224 RGB 컬러 이미지 입력을 처리할 수 있도록 설계

5개의 Convolution 레이어와 3개의 Fully Connected 레이어로 LeNet 대비 규모를 획기적으로 확장

AlexNet의 기술적 돌파구: ReLU, Dropout, GPU

활성화 함수 혁신: ReLU (Rectified Linear Unit)

Sigmoid를 버리고 ReLU를 본격 도입하여 기울기 소실 문제를 완화하고 학습 속도를 6배 이상 향상

과적합(Overfitting) 방지 기법: Dropout


Dropout: 학습 시 뉴런의 일부를 무작위로 생략하여 뉴런 간의 상호 의존성(Co-adaptation) 제거

데이터 증강(Data Augmentation): 이미지 랜덤 크롭, 좌우 반전 등을 통해 가상으로 데이터 확보

하드웨어 한계 극복: GPU 병렬 연산


당시 GPU(GTX 580)의 메모리 한계를 극복하기 위해 두 개의 GPU에 망을 나누어 병렬 학습 진행

AlexNet의 기술적 돌파구: ReLU, Dropout, GPU



AlexNet의 기술적 돌파구: ReLU, Dropout, GPU

합성곱층 다섯 개



전환 브릿지: 더 깊게 쌓자, 그런데 어떻게?

AlexNet 성공 이후의 학계 트렌드

연구자들의 공통 결론: '신경망의 레이어를 더 깊게(Deep) 쌓을수록 모델의 표현력과 성능이 올라간다'

새롭게 마주한 당면 과제와 VGGNet의 문제의식

AlexNet처럼 11x11, 5x5 등 다양한 크기의 커널을 무작정 섞어 쓰면 하이퍼파라미터 튜닝이 비정상적으로 복잡해짐

네트워크 설계의 규격화, 표준화, 단순화가 필요해진 시점

VGGNet (2014) – 3x3 필터로 통일된 직관적 구조

등장

옥스퍼드대학의 시각 기하학 그룹(VGG)이 제안한 아키텍처


구조가 극도로 직관적이고 규칙적이어서 훗날 객체 탐지(Object Detection) 등 다양한 테스트의 백본으로 활용

네트워크 레이어의 규격화

모든 합성곱 레이어의 커널 크기를 3x3, 패딩을 1로 완벽히 일치시킴

VGG-16, VGG-19 등 깊이에 따른 패밀리 모델 개념을 정립하여 실험적 증명 수행

VGGNet (2014) – 3x3 필터로 통일된 직관적 구조



$$\text{Output} = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1$$

W (Input Size): 입력 데이터의 크기 (가로 또는 세로)

K (Kernel Size): 커널(필터)의 크기

P (Padding Size): 패딩의 크기

S (Stride Size): 스트라이드(이동 간격)의 크기

왜 5x5 대신 3x3 필터를 여러 번 쌓았을까?

수용장(Receptive Field)의 동일성

3x3 Conv 레이어를 2번 연속으로 통과하는 것은 5x5 Conv 레이어 1번을 거치는 것과 동일한 영역의 특징을 인지함

Input(224) $\xrightarrow{5 \times 5 \text{ Conv (P=2)} \times 1}$ Output(224)

Input(224) $\xrightarrow{3 \times 3 \text{ Conv (P=1)} \times 2}$ Output(224)

이점 1: 파라미터 수의 극적인 감소


5x5 커널 1개의 채널당 파라미터: 25개

3x3 커널 2개의 채널당 파라미터: $9 + 9 = 18$ 개 (연산 가중치가 약 28% 감소)

이점 2: 결정 경계의 비선형성 증가


레이어가 늘어남에 따라 활성화 함수(ReLU)를 더 많이 거치게 되므로, 모델이 복잡한 특징을 학습하는 능력이 고도화됨

VGGNet (2014) – 모델별 형상



VGGNet 한계 (feat. VGG19)

- 열화 문제 (Degradation Problem) : 망이 너무 깊어 정보가 변질
- 활성화 함수의 한계로 인한 미세한 기울기 소실 (Gradient Vanishing)
- 가중치(파라미터) 폭발로 인한 학습 최적화의 한계



전환 브릿지: 무게 줄이기大作战과 구글의 생각

2014년의 평행 우주: 직렬 vs 병렬

VGGNet이 단순하고 깊은 직렬식 무거운 망을 만들 때, 구글(Google)은 전혀 다른 패러다임에 주목

GoogLeNet의 핵심 문제의식

성능 향상을 위해 깊게 쌓는 것에는 동의하지만, VGG 스타일은 서버 바깥의 기기(모바일, 임베디드)에서 구동 불가능
파라미터 개수와 연산 용량을 획기적으로 다이어트하면서도 깊이를 유지할 효율적 아키텍처 연구 촉발

GoogLeNet (2014) – 효율성과 병렬 연산의 극치

개요 및 대회 성과

ILSVRC 2014 대회에서 VGGNet을 근소한 차이로 제치고 최종 우승을 차지


인셉션 블록(Inception Block)이라는 독창적인 서브 네트워크 구조를 도입

압도적인 파라미터 감소

VGGNet(16층)보다 훨씬 더 깊은 총 22층의 본체 아키텍처 설계

그러나 총 가중치 파라미터 수는 VGGNet의 약 1/20 수준(약 700만 개)에 불과한 고효율 달성

GoogLeNet (2014) – 효율성과 병렬 연산의 극치



출처: GoogLeNet architecture, forward propagation from right to left (Illustration is taken from [3].)

GoogLeNet (2014) – 특징

공간적 특징의 병렬 추출 구조

하나의 층에서 고정된 커널을 쓰지 않고 `1x1`, `3x3`, `5x5` Conv와 `Max Pooling`을 수평 병렬로 동시 수행
다양한 크기의 수용장을 통해 거시적 특징과 미시적 특징을 한 번에 결합

1x1 Convolution의 차원 축소

3x3, 5x5 연산을 적용하기 직전에 가벼운 1x1 Conv를 배치하여 특성 맵의 채널 수를 대폭 압축
채널 압축 덕분에 공간 연산에 드는 가중치와 곱셈 연산량이 드라마틱하게 절감됨

보조 분류기(Auxiliary Classifier) 추가

중간에 소프트맥스 방을 임시로 만들어서 거기서 틀린 오차 점수를 가지고 중간 레이어 영역에 직접 미분 신호(기울기)를 강제로 유입

전환 브릿지: 깊이의 벽과 열화 문제(Degradation)

VGG와 구글이 열어젖힌 레이어 무한 경쟁

구조적 표준화와 병렬 효율화로 20~30층까지 안착 성공. 연구자들은 더 과감하게 50층, 100층 돌입

열화 문제(Degradation Problem) 대두


56층 망을 설계해 학습시켰더니, 오히려 기존 20층 망보다 학습 데이터와 테스트 데이터 전체에서 오차율이 폭증

이는 과적합(Overfitting)의 문제가 아니며, 망이 과도하게 깊어져 데이터의 본질적 신호가 끝까지 도달하지 못하고 파괴되는 현상

ResNet (2015) – 잔차 학습과 Skip Connection


지름길 (Skip Connection / Shortcut Connection / Identity mapping)

입력값 x 를 아무런 가중치 연산 없이 레이어 건너편 출력단으로 그대로 우회 통과시켜 더해주는 아이디어



잔차 학습(Residual Learning)

입력값 x 는 지름길을 통해 이미 출구에 배달되어 알고 있으니, 출력과의 차이(잔차)인 $F(x) = H(x) - x$ 만 코어레이어가 학습



ResNet (2015) – 기술적 의의


지름길 (Skip Connection / Shortcut Connection / Identity mapping)

순전파(Inference): 가공되지 않은 순수한 원본 픽셀 정보가 훼손 없이 맨 뒤 레이어까지 안정적으로 배달되어 열화 문제 해결

역전파(Training): 미분 신호가 거슬러 올라갈 때 지름길 축을 통한 x로 최소 1의 미분값을 무조건 보장받으므로, 기울기 소실 종식

잔차 학습(Residual Learning)

지름길을 활용해 최적화가 불필요한 레이어를 비활성화 $F(x)=0$ 함으로써, 깊어져도 기울기 소실이나 열화 현상 없이 최적의 성능



ResNet (2015) – 블록 특징

아이덴티티 블록

규격 변화가 없어서 실선 지름길로 원본을 그대로 통과시키는 평범한 2칸짜리 블록

합성곱 블록

해상도와 채널이 바뀌는 경계선이라 지름길에도 합성곱(1x1 Conv) 연산을 넣어주어야 하는 특별한 2칸짜리 블록







Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.

ResNet (2015) – VGG와 비교



결론: 한계 극복으로 이어진 CNN의 위대한 여정

5대 모델의 아키텍처 연대기

LeNet-5: 합성곱과 풀링이라는 신경망 아키텍처의 기본 표준 뼈대 제공

AlexNet: 대용량 연산(GPU), 데이터 증강, 활성화 함수(ReLU) 도입을 통한 암흑기 탈출

VGGNet: 3x3 소형 커널 반복 배치를 통한 딥러닝 네트워크의 규격화와 구조적 직관성 확립

GoogLeNet: 1x1 Conv 차원 축소와 인셉션 병렬 구조를 통한 저용량/고효율 신경망 모델 설계 개척

ResNet: 잔차 학습 지름길 구현으로 무한에 가까운 깊이 확장성 확보